

Tugas Take-Home Sesi 05
Transfer Learning untuk Klasifikasi Citra dengan Data Terbatas
Bagian A: Analisis Konseptual

Nama: Marvin Adriano Rusdianto **NIM:**2802402275

1. Efek Regularisasi pada Batch Normalization (Slide 6–8)

Saat training, BN memakai rata-rata dan variansi dari mini-batch, bukan dari seluruh data (Slide 6–7). Isi batch diacak di setiap iterasi, jadi nilai normalisasi untuk satu gambar ikut berubah tergantung gambar lain yang kebetulan satu batch dengannya. Ini menjadi noise kecil pada aktivasi, mirip efek Dropout, sehingga model sulit menghafal contoh tertentu (Slide 6, 8). Itulah alasan Slide 8 menyebut BN sebagai regularisasi ringan.

Tapi anggapan bahwa Dropout tidak diperlukan lagi tidak selalu benar. Slide 8 hanya menyebut BN sebagai regularisasi ringan yang sering (bukan selalu) menggantikan Dropout. Pada dataset kecil, overfitting masih bisa terjadi sehingga Dropout tetap berguna (Slide 20, 28). Selain itu, karena BN bergantung pada statistik mini-batch (Slide 6), batch size yang sangat kecil membuat rata-rata dan variansi batch terlalu berisik, sehingga training bisa menjadi tidak stabil.

2. Degradasi Jaringan Dalam dan Formulasi Residual (Slide 10–12)

Secara teori, jaringan yang lebih dalam minimal bisa meniru jaringan dangkal dengan menjadikan lapisan tambahan sebagai identity. Namun pada plain CNN hal ini tidak terjadi dalam praktik: Slide 10 menyebut jaringan yang lebih dalam kadang justru lebih buruk, dengan penyebab gradient vanishing/exploding dan information loss antar lapisan, sehingga training error malah naik.

Pada residual block, $y = F(x) + x$, jadi lapisan cukup belajar residu $F(x)$, dan identity tercapai kalau $F(x)$ mendekati nol. Saat backpropagation, $\partial L / \partial x = \partial L / \partial y \cdot (1 + \partial F / \partial x)$. Suku 1 itu meneruskan gradien langsung tanpa dikali bobot. Di Sesi 02, vanishing gradient muncul karena turunan kecil dikalikan berulang kali. Dengan skip connection, perkalian itu punya jalur pintas berupa penjumlahan, jadi gradien ke lapisan awal tetap sampai (Slide 11–12).

3. Feature Extraction vs. Fine-Tuning (Slide 14–16)

Parameter : Feature extraction hanya melatih head (ResNet-18, 10 kelas: 5.130 parameter). Fine-tuning ikut melatih lapisan yang di-unfreeze, dari layer yang dalam hingga seluruh backbone (Slide 16).

Data : Karena yang dilatih sedikit, feature extraction cocok untuk data terbatas (Slide 15). Fine-tuning melatih lebih banyak bobot, sehingga berisiko overfitting pada data kecil (Slide 28).

Komputasi dan memori : Feature extraction lebih ringan karena backbone tidak diperbarui. Fine-tuning menyimpan gradien dan state optimizer untuk lapisan yang dibuka, sehingga lebih lama dan boros memori.

Risiko merusak fitur : Backbone tetap pada feature extraction, jadi fitur bawaan aman. Pada fine-tuning, bobot pretrained ikut berubah dan bisa rusak jika terlalu cepat (Slide 28), sehingga learning rate dibuat lebih kecil (Slide 16).

Kriteria praktis : Mulai dari feature extraction (Slide 29); biasanya cukup jika data sedikit dan domain mirip ImageNet (Slide 15). Jika hasil mentok atau domain berbeda jauh, buka lapisan dalam secara bertahap (Slide 16).

4. Kaidah Penerapan Data Augmentation (Slide 20, 21, 23)

Augmentasi hanya dipakai di train set karena tujuannya membuat data latih lebih bervariasi supaya model lebih general (Slide 20). Validation dan test set dipakai untuk mengukur performa, jadi harus tetap, hasilnya sama setiap kali dievaluasi, dan mirip data asli. Kalau ikut diaugmentasi, skor jadi berubah-ubah dan tidak menggambarkan kondisi sebenarnya, dan early stopping bisa salah mengambil keputusan. Untuk dua set ini cukup Resize/Crop dan normalisasi.

Contoh yang tidak layak adalah color jitter yang terlalu kuat (Slide 21). Warna dan pola bulu sering menjadi ciri pembeda ras, jadi jika warna terlalu diubah, ciri itu hilang dan gambar tidak lagi sesuai dengan labelnya, sehingga model belajar dari sinyal yang keliru. Vertical flip juga kurang cocok karena hewan yang terbalik hampir tidak pernah muncul di data nyata (Slide 21).

5. Mitigasi Catastrophic Forgetting (Slide 28–29)

Bobot pretrained menyimpan fitur umum hasil belajar dari ImageNet (Slide 14). Kalau fine-tuning terlalu agresif, misalnya learning rate besar atau lapisan dibuka sekaligus, bobot bergeser jauh dari nilai awalnya. Dengan data kecil, model hanya menyesuaikan diri ke data baru, dan fitur umum tadi tertimpa (Slide 28).

Strategi pertama adalah learning rate yang lebih kecil saat fine-tuning (Slide 16), yang bisa diterapkan sebagai differential learning rate: lapisan awal kecil, lapisan akhir lebih besar. Slide 16 membuka lapisan yang lebih dalam lebih dulu, karena lapisan itu lebih spesifik ke tugas, sedangkan lapisan awal menyimpan fitur umum yang tidak perlu banyak diubah. Strategi kedua adalah gradual unfreezing: head dilatih dulu lewat feature extraction (Slide 29), lalu lapisan dibuka dari belakang ke depan (Slide 16). Perubahan bobot jadi kecil di tiap tahap, sehingga fitur pretrained tidak tertimpa sekaligus.